

Análisis Comparativo de Métodos de Muestreo en CMA-ES

Fernando Sampalo, Arturo Uceda, Ángel Gallego, David López

9 de junio de 2025

Resumen

Este informe presenta un análisis comparativo de tres métodos de muestreo en el algoritmo CMA-ES (Covariance Matrix Adaptation Evolution Strategy): muestreo Gaussiano clásico, secuencia de Sobol y Latin Hypercube. Se evalúan estos métodos en un conjunto diverso de funciones de prueba de optimización, analizando su rendimiento en términos de convergencia, precisión y tiempo de ejecución. Los resultados muestran diferencias significativas entre los métodos, con implicaciones importantes para la selección de estrategias de muestreo en problemas de optimización reales.

1. Consideraciones

- La ejecución del código suele tardar en torno a 2 minutos.
- Enlace al repositorio de GitHub, para posibles contribuciones: <https://github.com/fsampalo/Experimentacion-CMA-ES>

2. Introducción

El CMA-ES es un algoritmo de optimización evolutiva que ha demostrado ser particularmente efectivo en problemas de optimización continua. Un aspecto crucial de su funcionamiento es el método de muestreo utilizado para generar nuevas soluciones candidatas. En este estudio, se comparan tres enfoques de muestreo diferentes, cada uno con sus propias características y ventajas potenciales.

3. Métodos de Muestreo

3.1. Muestreo Gaussiano Clásico

El muestreo Gaussiano clásico es el método tradicional utilizado en CMA-ES. Genera soluciones candidatas mediante una distribución normal multivariada, donde la matriz de covarianza se adapta durante la evolución del algoritmo. Este método se caracteriza por:

- Generación de puntos siguiendo una distribución normal
- Adaptación de la matriz de covarianza basada en el rendimiento
- Exploración del espacio de búsqueda mediante perturbaciones aleatorias

3.2. Secuencia de Sobol

La secuencia de Sobol es un método de muestreo de baja discrepancia que proporciona una cobertura más uniforme del espacio de búsqueda. Sus características principales incluyen:

- Generación determinista de puntos
- Mejor distribución espacial que el muestreo aleatorio
- Reducción de la varianza en la estimación

3.3. Latin Hypercube

El muestreo Latin Hypercube divide el espacio de búsqueda en estratos y selecciona un punto de cada estrato, asegurando una cobertura más uniforme. Sus ventajas incluyen:

- Mejor cobertura del espacio de búsqueda
- Reducción de la correlación entre dimensiones
- Mayor eficiencia en la exploración del espacio

4. Configuración Experimental

4.1. Parámetros del Experimento

- Dimensión del problema: 10 (ajustada a 8 para la función Powell)
- Tamaño de la población: 50 individuos
- Número máximo de iteraciones: 100
- Número de ejecuciones: 30 por cada combinación de método y función
- Rango de búsqueda: $[-5, 5]$ en todas las dimensiones

4.2. Funciones de Prueba

Se evaluaron las siguientes funciones de prueba:

- Sphere (parábola simple)
- Rosenbrock (valle curvo)
- Rastrigin (múltiples mínimos)
- Ackley (oscilaciones complejas)
- Schwefel (mínimos engañosos)
- Griewank (muchos óptimos)
- Levy (desafío multimodal)

- Zakharov (cuadrática compleja)
- Dixon-Price (alta dimensionalidad)
- Powell (mal condicionada)
- Sum-Squares (suma cuadrática)
- Trid (interacciones cuadráticas)

5. Resultados y Análisis

5.1. Análisis de Convergencia

Los resultados muestran diferencias significativas en la velocidad de convergencia entre los métodos de muestreo. En general:

- **El muestreo Gaussiano** muestra un comportamiento más errático pero con capacidad de escape de óptimos locales. A pesar de todo, es el modelo que peores resultados alcanza, y más tiempo tarda en obtenerlos.
- **La secuencia de Sobol** proporciona una convergencia más estable y predecible. Se trata del modelo que en general, obtiene los resultados más precisos. Este hecho sugiere que la generación de puntos a partir de las plantillas Sobol, puede ser efectivo.
- **Latin Hypercube** muestra un buen balance entre exploración y explotación. Alcanza buenos resultados, parecidos a Sobol, con la diferencia de que suele tarda más iteraciones en converger.

A continuación, vamos a mostrar algunos resultados interesantes con algunas funciones. Todas las comparaciones se encuentran en la carpeta 'imgs':




Figura 1: Comparación de convergencia en la función Sphere

Observamos en la **figura 1** como la secuencia de Sobol y Latin Hypercube obtienen resultados similares. En cambio, el Gaussiano no presenta convergencias rápidas y precisas en pocas iteraciones.




Figura 2: Comparación de convergencia en la función Rastrigin

La **Figura 2** muestra que Sobol y Latin Hypercube logran resultados comparables, en contraste con el método Gaussiano, que no alcanza una convergencia rápida.




Figura 3: Comparación de convergencia en la función Rosenbrock

Como se ilustra en la **Figura 3**, Sobol y Latin Hypercube exhiben un comportamiento similar, mientras que el Gaussiano presenta convergencia menos eficiente en pocas iteraciones.




Figura 4: Comparación de convergencia en la función Ackley

En la **Figura 4**, se destaca que Sobol y Latin Hypercube tienen un rendimiento cercano, mientras que el método Gaussiano converge con menor precisión inicialmente.




Figura 5: Comparación de convergencia en la función Zakharov

La **Figura 5** revela que las secuencias de Sobol y Latin Hypercube son comparables en convergencia, a diferencia del Gaussiano, que requiere más iteraciones para resultados precisos.

5.2. Análisis Estadístico

Se realizaron pruebas estadísticas (Mann-Whitney U) para comparar los métodos por pares. Los resultados muestran:

Función	Gaussiano vs Sobol	Gaussiano vs LHC	Sobol vs LHC
Sphere	0,0001	0,0001	0.7845
Rosenbrock	0,0001	0,0001	0.4119
Rastrigin	0,0001	0,0001	0,0001
Ackley	0,0001	0,0001	0,0001
Schwefel	0.3545	0.0001	0.0001

Cuadro 1: Valores p de las pruebas estadísticas (Mann-Whitney U)

Las pruebas estadísticas (Mann-Whitney U) indican diferencias significativas ($p < 0.0001$) entre los métodos Gaussiano vs. Sobol y Gaussiano vs. LHC para todas las funciones, y entre Sobol vs. LHC para Rastrigin, Ackley y Schwefel. Sin embargo, no se encontraron diferencias significativas entre Sobol y LHC para Sphere ($p = 0.7845$) y Rosenbrock ($p = 0.4119$).

5.3. Tiempos de Ejecución

El análisis de tiempos de ejecución revela:

- El muestreo Gaussiano es generalmente el más rápido
- La secuencia de Sobol requiere más tiempo computacional
- Latin Hypercube muestra tiempos intermedios




Figura 6: Comparación de tiempos de ejecución entre métodos

6. Discusión

Los resultados obtenidos sugieren que la elección del método de muestreo debe basarse:

- La naturaleza del problema de optimización
- Los requisitos de tiempo computacional
- La necesidad de exploración vs. explotación

En síntesis, si no requerimos de velocidad, pero si de precisión, la secuencia de Sobol y Latin Hypercube presenta mejores resultados.

7. Conclusiones

- No existe un método de muestreo óptimo para todos los problemas. En nuestro ejemplos, la secuencia Sobol es la que muestra una convergencia en menos iteraciones, y de mayor calidad (minimiza antes)
- La secuencia de Sobol y Latin Hypercube muestran ventajas en problemas complejos, de forma que son capaces de alcanzar la convergencia antes.
- El muestreo Gaussiano mantiene su utilidad en problemas más simples, pero en problemas complejos no es escalable, lo que requerirá muchas iteraciones en la ejecución.

8. Extensiones Futuras

Posibles direcciones para investigación futura:

- Análisis de métodos híbridos de muestreo
- Adaptación dinámica del método de muestreo durante la optimización
- Estudio de la escalabilidad en problemas de mayor dimensión
- Aplicación a problemas de optimización reales
- Agregar nuevas direcciones de exploración, de forma que sea menos sensible a problemas de múltiples óptimos locales.